

Two-Stage Algorithmic Trading: XGBoost-Enhanced Technical Signals

Chun Hung Tsang (曾俊雄)

第一章 研究背景與動機

在現代金融市場中，量化投資已成為提升交易效率與回撤管控的核心手段。台灣股票市場具有高波動性與產業集中度高的特性，傳統僅依賴固定參數的技術指標策略，往往容易在市場環境切換（如趨勢轉盤整）時產生過度交易與無效訊號。

本研究之動機在於結合傳統技術分析之結構性邏輯與機器學習之資料驅動能力，建立一個具備環境適應性的兩階段交易系統。透過同時納入反轉、趨勢與動能三種不同性質的指標，本報告旨在解決單一指標對特定市場狀態過於敏感的問題。核心研究目標為實證在考慮實際交易成本與嚴格風險控制的情境下，利用 XGBoost 模型作為二階濾網，能否有效識別高勝率交易機會，進而在 2017 至 2025 年的測試期中創造優於大盤的風險調整後收益。

第二章 資料說明與處理

本報告使用台灣股票市場之日頻率歷史交易資料，樣本期間自 2013 年 1 月 1 日至 2025 年 11 月 25 日。原始資料共包含 776 檔證券。本報告依據證券代碼與商品性質進行篩選，移除權證、ETF、可轉債及其他非普通股之金融商品。篩選後，最終樣本由 746 檔上市與興櫃公司之普通股構成。

所有價量資料皆以台灣股票市場正式交易日為基準，資料以股票代碼與交易日期為雙重索引，形成典型之縱橫資料結構。對於每一檔股票而言，每日開盤價、最高價、最低價、收盤價與成交量所構成之時間序列，完整描述其歷史交易行為。

第三章 技術指標與交易訊號設計

本報告之投資策略以三種技術指標作為基礎交易訊號來源，分別為 RSI 結合 ATR、DMA 結合 ADX，以及 MACD。三者分別對應市場中不同型態的價格行為，涵蓋短期反轉、中期趨勢與動能變化等面向。透過同時納入不同性質的技術指標，本報告避免策略僅對單一市場狀態敏感，並提升在多樣市場環境下的適應能力。

本章僅說明各技術指標之交易邏輯與訊號設計概念，不涉及模型整合、權重配置或績效評估，相關策略整合機制將於後續章節說明。

3.1 RSI 結合 ATR 之反轉型交易策略

本策略旨在捕捉市場短期過度反應後的修正機會。

- 交易邏輯：**利用 RSI 指標判斷超買與超賣狀態。當 RSI 低於進場門檻（rsi_b）時判定為過度拋售，產生做多訊號；當 RSI 高於門檻（rsi_s）時判定為動能過度擴張，產生做空訊號。

- **風險控制**：引入 ATR 指標以反映市場當前波動。進場後的停損距離由 ATR 乘上倍率參數（atr_m）決定，確保在市場波動劇烈時給予部位較大的震盪空間，而在波動收斂時嚴格執行風險管控。

3.2 DMA 結合 ADX 之趨勢型交易策略

本策略側重於確認趨勢形成後的順勢操作，並透過強度濾網過濾盤整雜訊。

- **交易邏輯**：以短期與長期移動平均線（f_ma, s_ma）的交叉作為核心訊號。當短均線由下往上穿越長均線時看多，反之則看空。
- **趨勢濾網**：為避免在盤整行情中被反覆洗出場，本策略加入 ADX 指標。只有當 ADX 顯示趨勢強度超過預設門檻（adx_t）時，均線交叉訊號才會被視為有效的候選交易。

3.3 MACD 之動能變化交易策略

本策略著重於價格動能的轉折辨識，補足趨勢策略在初期反應較慢的不足。

- **交易邏輯**：觀測 MACD 快線、慢線與訊號線的相對位置及變化率。當 MACD 柱狀體由負轉正，或動能變化方向明顯向上時，視為動能轉強的早期訊號而進場做多；反之則執行做空交易。
- **風險預警**：MACD 預警分為兩種。
 - 低檔背離：現象為價格創新低但 MACD 低點卻墊高。這代表空頭力道耗盡，為反轉向上的預警，需準備買入。
 - 高檔背離：現象為價格創新高但 MACD 高點卻降低。這代表多頭力道衰竭，為行情反轉向下的警訊，需準備賣出並嚴格執行風控。

第四章 交易訊號整合（一節）與決策流程（二節）設計

本報告之交易決策採用兩階段設計，第一階段由三個技術指標各自產生具明確方向性的交易訊號，第二階段則透過 XGB 模型對這些訊號進行資料驅動的品質判斷。此設計使技術指標負責提出可交易的候選時點，而機器學習模型負責評估在當下市場與个股狀態下，哪些訊號具備較高的成功機率，從而避免僅依賴固定規則所造成的過度交易。

4.1 第一階段：技術指標對做多與做空訊號的具體判定

在第一階段中，三個技術指標於每一交易日、每一檔股票上，根據當日的價格與成交量資訊，獨立判斷是否存在可執行的方向性交易機會。每一筆由指標所產生的訊號，皆已明確指定交易方向，亦即做多或做空，不存在方向未定的情形。

RSI 結合 ATR 的策略屬於反轉導向。當 RSI 顯示價格在短期內進入相對低檔區間時，代表市場可能出現過度拋售現象，策略將此視為潛在反彈機會而產生做多訊號；相對地，當 RSI 進入相對高檔區間時，代表短期上漲動能可能已過度擴張，策略則產生做空訊號。進場後，部位的風險控制與出場判斷並非採用固定停損，而是依據 ATR 所反映之當期市場波動程度動態調整，使停損距離能隨波動放大或收斂，避免在高波動行情中過早被動出場。

DMA 結合 ADX 的策略則屬於趨勢導向。當短期移動平均線由下向上穿越長期移動平均線，且 ADX 顯示趨勢強度達到設定門檻時，策略判定市場已形成具延續性的上升趨勢，進而產生做多訊號；反之，當短期均線由上向下穿越長期均線，且趨勢強度同樣達標時，則判定市場進入下降趨勢並產生做空訊號。由於 ADX 在此僅作為趨勢強度濾網，此策略在趨勢不明顯或市場盤整時通常不會產生任何交易訊號。

MACD 所對應的策略著重於動能變化而非價格水準本身。當 MACD 顯示動能由弱轉強，或動能變化方向明顯向上時，策略視此為動能轉折的早期訊號而產生做多建議；反之，當動能由強轉弱或出現明顯下滑時，則產生做空訊號。相較於前兩者，MACD 對於趨勢初期與趨勢末端的變化較為敏感，能補足反轉型與趨勢型策略在動能轉折辨識上的不足。

在此第一階段中，只要任一技術指標於某一交易日對某一股票產生做多或做空訊號，該訊號即被視為一筆候選交易，進入下一階段進行進一步評估。

4.2 第二階段輸入：XGB 分割所使用的個股與市場訊號

所有由第一階段產生的候選交易，並不會立即執行，而是先在訊號發生當下轉換為 XGB 模型可處理的特徵向量。這些特徵同時包含個股層級與市場層級的資訊，使模型在進行樹節點分割時，能同時考量個別股票的即時狀態與整體市場環境。

在個股層級，特徵主要描述該股票當下的價格結構、動能與波動特性，例如近期報酬變化、價格相對於不同期間均線的位置、短中期波動程度，以及成交量相對於近期平均水準的變化。這些資訊使模型能判斷，在目前的價量結構下，該筆交易是否容易受到短期雜訊干擾，或是否具備延續性。

在市場層級，模型同時納入反映整體市場狀態的訊號，例如市場中多數股票相對於中期均線的位置分布、整體價格離散程度、整體波動水準，以及市場成交量是否顯著放大。這些特徵使 XGB 在分割樹節點時，能有效區分不同市場情境，例如趨勢明確與震盪盤整、高波動與低波動環境，進而學習在何種市場狀態下，來自不同技術指標的訊號較具成功機率。

透過同時結合個股與市場訊號，XGB 並非僅在「單一股票是否適合交易」的層次做判斷，而是進一步學習「在何種市場背景下，某一類型的交易訊號才值得被執行」。

4.3 XGB 模型之訓練目標、方向處理與機率輸出意義

XGB 模型的訓練樣本，來自歷史資料中所有已實際完成出場的候選交易。每一筆樣本在進入模型訓練前，已明確對應一個交易方向，亦即做多或做空，該方向由第一階段技術指標所決定，並在整筆交易期間內保持不變。

模型的訓練標籤並非定義為價格是否上漲或下跌，而是定義為「在既定交易方向下，該筆交易最終是否產生正的淨報酬」。因此，當一筆做多交易在出場時獲利，或一筆做空交易在出場時同樣獲利，該樣本皆被標記為成功；反之，若該筆交易最終虧損，則被標記為失敗。此設計使模型直接學習交易結果本身，而非單純的價格方向預測。

由於訓練資料中同時包含做多與做空樣本，且每一筆樣本均保留其方向資訊，XGB 能在樹結構中自然學習到在不同特徵組合下，哪一種方向的交易較容易成功，而無需為做多與做空分別訓練獨立模型。

模型在節點分割時，會根據個股與市場特徵，自動形成對做多或做空較有利的區域。

在實際預測時，XGB 對每一筆候選交易輸出一個介於 0 與 1 之間的機率值，其意義為：在目前特徵條件與既定交易方向下，該筆交易最終能產生正淨報酬的機率。若該候選交易為做多，則此機率代表做多成功的機率；若為做空，則代表做空成功的機率。需要特別強調的是，此機率並非價格上漲或下跌的機率，因此亦不能簡單地以一減該值來解讀為反方向成功的機率。

在實際執行時，對於同一股票、同一交易日可能同時出現的多筆候選交易，策略會分別計算其對應的成功機率，並僅在最高機率高於預設門檻值時才執行交易。此流程確保每一筆實際進場的交易，皆同時通過技術指標所提供的結構性判斷，以及 XGB 模型基於歷史資料所學得的成功機率評估。

第五章 滾動視窗訓練設計

本報告採用滾動視窗訓練與回測架構，每一個視窗包含四年的訓練期與一年的測試期，並沿時間向前推進。就程式設計而言，四年訓練期並未被視為單一整體資料直接用於模型訓練；相反地，研究將四年訓練期內的年度序列再切分為三組連續的一年訓練與一年驗證配對，亦即若四年訓練期涵蓋年度 T_1, T_2, T_3, T_4 ，則形成 $(T_1 \rightarrow T_2)$ 、 $(T_2 \rightarrow T_3)$ 、 $(T_3 \rightarrow T_4)$ 三組「一年訓練＋一年驗證」的子流程。程式中明確以相鄰年度迴圈方式建立此結構：以某一年作為參數最佳化年度 (Opt Year)，並以緊接其後一年作為訊號生成與驗證年度 (Exe Year)。

此設計的核心在於嚴格分離「參數校準」與「策略/模型評估」所使用的資料來源。在每一組子流程中，訓練年僅用於調整第一階段技術指標所需的參數；第一階段技術指標的一篩訊號產生，以及第二階段 XGB 的二篩決策與標籤生成，均在驗證年上執行，並且是以「用前一年校準出的參數，去跑下一年」的方式完成。這使每一組子流程都符合實務量化交易「以過去資訊制定規則，在未來一期檢驗」的時間一致性要求，同時降低在同一段資料上反覆調參與評估所造成的過度擬合風險。

5.1 四年訓練期內三組「一年訓練＋一年驗證」的功能分工

在每一個四年訓練期中，三組相鄰年度配對並非僅為增加樣本量，而是用來在多個市場狀態下重複進行「參數校準→驗證」的過程，從而讓技術指標與二階段模型都能接觸到不同年度的波動水準、趨勢型態與成交量結構。程式中對每一組 (Opt Year→Exe Year) 的處理方式一致：先在 Opt Year 針對一小組代表性股票進行參數最佳化，再將最佳化參數套用於 Exe Year 生成交易訊號與交易結果，並據此形成 XGB 的訓練資料。

就功能而言，三組子流程的第一個目的，是避免使用整段四年資料一次性調參而隱含「參數在四年內固定且最適」的強假設。若直接以四年資料做單次最佳化，參數往往會偏向某一段市場型態的平均效果，且難以辨識參數是否具有跨年度穩定性。改採逐年訓練與逐年驗證後，任何一組參數都必須在緊接的下一年接受檢驗；若參數僅在校準年度有效、但在下一年失效，便會直接反映在驗證年的交易結果中，進而影響 XGB 後續對「何種條件下訊號較可靠」的學習。

第二個目的，是為二階段 XGB 提供「樣本外風格」的訓練資料。由於 XGB 的標籤來自驗證年的實際交易結果，而交易觸發是由「前一年校準的參數」所產生的一篩訊號，因此 XGB 學到的是一個更接近部署情境的問題：在某一年度的市場與個股狀態下，特定指標訊號是否有較高機率帶來正淨報酬。

這與直接把四年資料混在一起、同時調參與生標籤相比，更能避免資料洩漏與「在同一資料上自我驗證」的偏誤。

5.2 訓練年：技術指標參數最佳化內容與參數意義

在每一組子流程的訓練年 (Opt Year)，程式以 Optuna 進行三個技術指標的參數搜尋，目標函數以策略在該年度的損益表現為準則並求最大化，且最佳化時僅使用一組流動性較高的代表性股票，以降低計算負擔並提高參數搜尋的穩定性；程式以訓練年之平均成交量排序，選取成交量最高的前十檔股票作為調參樣本。

在 RSI+ATR 策略中，被最佳化的參數包含 RSI 的計算期數 (rsi_p)、進場的低檔門檻 (rsi_b) 與高檔門檻 (rsi_s)，以及 ATR 的倍率參數 (atr_m)。其中 rsi_p 控制 RSI 對短期波動的敏感度，期數越短則訊號越敏感但雜訊也越大；rsi_b 與 rsi_s 則分別決定做多與做空進場的觸發條件，反映策略對「超賣」與「超買」狀態的定義；atr_m 用於將 ATR 轉換為動態停損/追蹤距離，其數值越大代表允許更大的浮動空間、降低被雜訊洗出場的機率，但也會放大單筆交易的風險承擔。值得注意的是，程式中 ATR 的計算期數固定為 14，代表研究將「ATR 的尺度估計窗口」視為結構性設定，而主要透過倍率 atr_m 來調整風險控制強度。

在 DMA+ADX 策略中，被最佳化的參數包含短期與長期移動平均線的窗口長度 (f_ma、s_ma)，以及 ADX 的計算期數 (adx_p) 與趨勢強度門檻 (adx_t)。其中 f_ma 與 s_ma 共同決定趨勢訊號的反應速度：短期均線越短、長期均線越長，越容易捕捉趨勢轉折但也更易受到盤整假訊號干擾；adx_p 決定趨勢強度衡量的平滑程度；adx_t 則是一個明確的「趨勢濾網」門檻，只有當趨勢強度達到此門檻時，均線交叉訊號才會被視為可交易。

在 MACD 策略中，被最佳化的參數包含快線、慢線與訊號線的計算期數 (f_p、s_p、sig_p)。這三者共同決定 MACD 對動能變化的反應速度：快線期數較短會使指標更敏感，慢線期數較長會使趨勢基準更平滑，而訊號線期數則控制交叉判斷的平滑程度。此類參數本質上是在「提早捕捉動能轉折」與「降低雜訊誤判」之間取得平衡。

5.3 驗證年：兩階段訊號執行與 XGB 訓練資料生成

在每一組子流程的驗證年 (Exe Year)，程式將訓練年最佳化所得參數固定下來，並實際對驗證年的一組較大股票集合生成三個技術指標的一篩訊號。為提高策略的可交易性與資料有效性，驗證年樣本同樣以成交量作為流動性代理指標，選取成交量較高的前五十檔股票進行訊號生成。

更關鍵的是，本報告的第二階段 XGB 並不是在「訓練年」上運行，而是以「驗證年」上由一篩訊號觸發的交易結果來建立監督式學習資料。程式的資料建構邏輯是：當一篩訊號在某一天觸發進場，系統記錄進場點與方向；當同一筆交易在後續某一天觸發出場時，計算該筆交易的淨損益，並以「淨損益是否為正」作為二元標籤。此時，模型輸入特徵取自進場當天的特徵向量，並額外加入策略識別與同儕訊號，使模型能學習在相同市場條件下，不同策略訊號或訊號組合的可靠度差異。

在此資料結構下，XGB 的學習目標被定義為「給定進場當下的個股與市場特徵，以及該筆交易所對應的一階策略訊號資訊，預測此筆交易最終是否能產生正淨報酬」。因此，XGB 的訓練資料天然同時包含做多與做空的樣本，且做多與做空並非被拆成兩個模型，而是以同一個二元分類模型共同學習

「在既定方向下是否成功」。這也正是為何研究必須在四年訓練期內採用三組「一年訓練＋一年驗證」：因為只有透過多次「用前一年校準參數、在下一年生成交易與標籤」的過程，才能累積足夠且具樣本外性質的交易樣本，使二階段模型不會只在單一年度或單一市場型態上學到偏誤的決策邏輯。

5.4 為何在四年訓練期內再設計三組一年訓練與一年驗證之滾動結構

乍看之下，本報告於訓練設計中採用的結構具有巢狀滾動視窗的特性：整體回測架構已採用「四年訓練加一年測試」的滾動視窗，而在每一個四年訓練期內，又進一步切分為三組連續的一年訓練與一年驗證。此設計表面上看似重複使用滾動視窗，確實不具直觀性，因此有必要清楚說明此兩層滾動設計各自所解決的問題，以及為何無法以單一的「四年訓練加一年驗證」結構取代。

首先，外層的四年訓練加一年測試滾動視窗，主要目的在於模擬實務量化交易中「以過去數年資料建立策略，並於下一年實際部署與評估」的情境。此層次的切分處理的是策略與模型在樣本外期間的整體穩健性評估問題，亦即回答「在某一歷史時間點可得的資訊下，策略在下一年是否仍能維持表現」。然而，外層滾動視窗並未處理另一個同樣關鍵的問題：在這四年訓練資料內，策略參數與訊號品質是否具有時間穩定性。若直接將四年訓練資料視為單一整體，並在其上一次性完成技術指標參數最佳化、訊號生成與模型訓練，等同於隱含假設策略在這四年間的行為結構大致不變，且以某一組「全期最適」參數即可代表未來的決策規則。對於價格行為與波動結構隨時間明顯演變的金融市場而言，此假設過於強烈，也不符合實務上逐期調整策略的操作邏輯。

因此，本報告在四年訓練期內引入第二層滾動結構，其目的並非再一次進行樣本外測試，而是用來在訓練資料內部，刻意製造多次「準樣本外」的驗證情境。透過將四年資料切分為三組相鄰的一年訓練與一年驗證，研究可以重複檢驗「在某一年校準出的技術指標參數與交易規則，是否能在緊接其後的一年中維持有效性」。這種設計使每一組參數與一階訊號都必須通過時間推進後的檢驗，而非僅在其校準期間內表現良好。

若僅在四年訓練期中切出單一組訓練與驗證，例如以前三年作為訓練、第四年作為驗證，則整個參數與訊號評估將高度依賴特定年度的市場狀態。若該年度恰好處於趨勢行情或異常波動階段，所得出的結論將難以推廣至其他市場情境。相較之下，三組連續的一年訓練與一年驗證設計，使研究能在同一個四年訓練期內，觀察策略在不同年度轉換時的表現，降低結論對單一市場階段的依賴程度。

此外，內層滾動視窗亦與第二階段 XGB 模型的訓練需求直接相關。由於 XGB 的監督標籤來自驗證年度中實際發生並完成出场的交易結果，若僅存在單一驗證年度，模型能學習的交易樣本數量與市場型態將相對有限。透過三個相鄰年度的驗證期，模型得以在同一個外層訓練視窗中，累積來自多個時間點的交易樣本，並學習在不同市場背景下，哪些一階訊號較具成功機率。這對於提升模型對樣本外測試期的泛化能力具有實質幫助。

總結而言，外層的四年訓練加一年測試滾動視窗，負責回答策略在樣本外期間的整體可行性；而內層於四年訓練期內再切分的三組一年訓練與一年驗證滾動結構，則用來檢驗策略參數與一階訊號在時間上的穩定性，並為二階模型提供多期、準樣本外性質的訓練資料。兩層滾動視窗處理的是不同層次的問題，彼此並非重複，而是互補，這也是本報告未採用單一「四年訓練加一年驗證」結構，而選擇內建三組一年滾動驗證設計的根本原因。

第六章 測試期交易執行

本報告之測試期涵蓋 2017 年至 2025 年，並以嚴格的時間序列滾動視窗方式執行投資策略，以確保測試結果具備樣本外性與實務可行性。測試期交易執行並非將整段期間一次性回測，而是依循「四年訓練加一年測試」的滾動架構逐年向前推進，模擬策略在實際部署情境下定期重新校準並投入市場運作的流程。

6.1 測試期滾動視窗與年度部署方式

在測試期中，每一個測試年度皆對應一組獨立完成的訓練流程。具體而言，策略首先使用 2014–2017 年的資料完成一次完整訓練，並將所得之策略設定部署於 2018 年進行交易執行；隨後視窗向前滾動一年，改以 2015–2018 年訓練並於 2019 年執行測試。此流程依序推進，最終形成一系列連續的一年測試期，串接為 2017–2025 年的完整測試期績效。該流程在程式中由年度迴圈明確控制，確保每一測試年度僅使用其之前可得的歷史資料完成訓練與部署。

6.2 測試期參數來源與固定原則

在每一個測試年度中，三個技術指標（RSI+ATR、DMA+ADX、MACD）所使用的參數，並非重新調整，而是固定採用該四年訓練期內「最後一年」所最佳化的參數設定。此設計反映實務交易中的合理假設：在進入新一年度前，交易者僅能依據最近一期的市場資訊選擇最具代表性的參數，而無法事後回頭利用更早或未來的資料重新調整。

因此，在測試期中，技術指標僅負責依固定參數生成交易訊號，XGB 模型亦以固定權重與門檻執行判斷，不存在任何形式的測試期再訓練或動態調參行為。

6.3 每日交易執行順序與訊號整合流程

測試期的交易執行以「每日逐筆」方式進行，並在每一交易日嚴格遵循固定的執行順序。程式於每日首先檢查是否存在既有持倉，若存在，則優先評估是否觸發任何平倉條件；僅在無持倉狀態下，才進入進場訊號的判斷流程。

在進場判斷階段，三個技術指標分別產生其方向性訊號。凡任一指標於該日產生進場訊號，即形成候選交易。對每一候選交易，系統會將當日的个股特徵、市場特徵、策略識別碼與同儕訊號組合成特徵向量，並輸入 XGB 模型以取得該筆交易在既定方向下產生正淨報酬的預測機率。

若同一日存在多筆候選交易，系統會依預測機率高低排序，僅保留預測機率最高者作為當日可執行交易。

6.4 方向性機率門檻與非線性資金配置

測試期中，XGB 模型所輸出的預測機率同時扮演「是否進場」與「資金配置比例」的雙重角色。策略對做多與做空交易採用不同的進場門檻：做多交易需滿足 60% 的預測機率門檻，做空交易則需滿足 70% 的預測機率門檻。此不對稱設計反映放空交易在實務上面臨較高的不確定性與尾端風險，因此要求模型提供更高的信心水準方允許進場。

當預測機率高於門檻時，資金配置權重依下列非線性公式計算：

$$w = \left(\frac{p - \tau}{1 - \tau} \right)^2$$

其中 p 為 XGB 預測機率， τ 為對應方向之門檻值。此非線性設計使資金配置對高信心交易更為集中，而對僅略高於門檻的交易維持保守配置。若為放空交易，該權重會再乘以一個 SHORT_FACTOR（本報告最終採用 1%）進行額外縮放，以進一步控制放空方向的資金曝險。

6.5 交易成本之設定與實際扣除方式

測試期交易成本在策略執行過程中被即時計入淨損益計算，而非事後調整。依程式設定，交易成本結構如下：對於做多交易，僅在平倉時收取 0.4% 的交易成本；對於做空交易，除在平倉時同樣收取 0.4% 的交易成本外，另於進場時額外收取 0.2% 的放空相關成本。

此設計使所有策略績效、XGB 訓練標籤與測試期結果，皆已內含交易成本影響，避免模型在無成本假設下學習而導致實際部署時的績效落差。

6.6 出場（平倉）機制與風險控制

測試期中，每一筆交易的出場邏輯完全由其進場時所對應的技術指標與風險控制規則共同決定，模型不介入持有期間的管理。系統每日檢查是否觸發下列任一平倉條件：

第一，固定比例停損：當未實現報酬低於預設停損門檻時立即平倉，本報告採 15% 停損點；第二，追蹤回撤停損：當價格自有利方向高點（或低點）回撤超過門檻時平倉，本報告採 15% 回撤比例；第三，最長持有期間限制：當持有天數達到上限即強制平倉，本報告採 80 個交易日為持有天數上限；第四，策略訊號反轉：當原進場策略於當日產生明確出場訊號時平倉。平倉後，該筆交易的實現損益即被確認，並計入累積績效與後續分析資料集中。

6.7 測試期績效的形成方式

整體測試期績效係由 2017–2025 年間各年度測試結果依時間順序串接而成。每一年度的交易結果，皆來自於一組僅使用該年度之前資料完成訓練與部署的策略設定，彼此之間不存在參數或模型資訊的交叉使用。此設計確保整體績效評估反映策略在長期、動態部署情境下的實際表現，而非單一靜態回測結果。

第七章 回測投資績效與風險分析

7.1 整體投資績效概述（2017–2025）

本節首先從整體層面評估本報告所建構之投資策略在測試期的累積績效表現。在實際執行中，策略對每一檔股票獨立判斷每日是否進場、持有或平倉，因此本節以 746 支股票構成之等權重投資組合為評估對象。

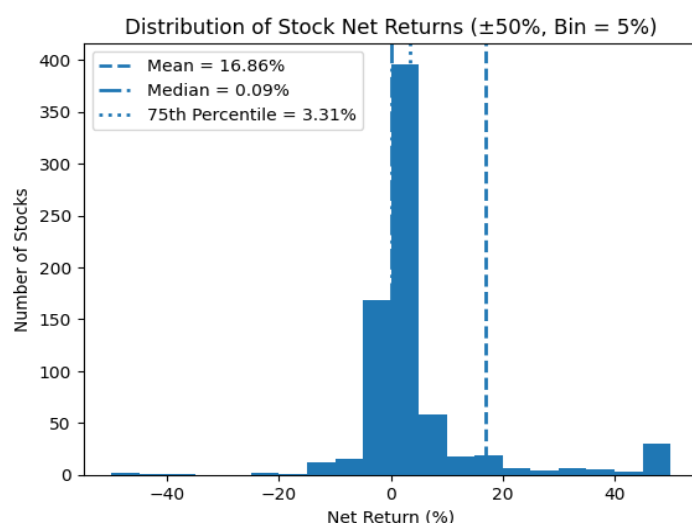
在不考慮任何交易成本的情況下，策略於整體測試期所產生的最終累積毛報酬（Final cumulative gross return）為 1475.77%。考慮實際交易成本後，包括每筆平倉時固定徵收 0.4% 的交易成本，以及做空交易於進場時額外徵收 0.2% 的放空成本，策略的最終累積淨報酬（Final cumulative net return）為 926.02%。兩者之差，即測試期內因實際交易所累積產生的總交易成本，約為 549.75%。同時比較同期台灣股市大盤指數的 146.58%，顯示策略的長期收益來源並非僅依賴市場整體上行，而是來自個股層級的主動交易決策。

以測試期涵蓋之實際交易日數（共 3248 個交易日）為基礎計算，策略的年化毛報酬率約為 36.32%，而在扣除交易成本後，年化淨報酬率約為 29.91%。兩者之差約為 6.42%，可視為策略在年度層級下，因交易成本而付出的平均績效代價。

從投資組合層級的風險調整績效來看，該等權重組合在測試期內的日勝率約為 34.63%，顯示策略並非依賴極高的單筆勝率，而是透過風險控制、部位配置與報酬分布的不對稱性累積長期收益。在風險調整後績效方面，本報告策略的 Sharpe ratio 為 3.27，而同期台灣股市大盤的 Sharpe ratio 僅為 0.74。此結果顯示，在承擔單位風險所能換取的超額報酬上，策略的效率顯著高於被動持有大盤指數。本報告策略的投資組合每日波動率約為 2.08%，年化波動率為 33.02%，相對應的大盤年化波動率則約為 15.87%。在下行風險方面，本報告策略於測試期內的最大回撤為-387.64%，而同期台灣股市大盤的最大回撤約為 -30.98%，顯示策略承受更多風險。

7.2 個股層級最終淨回報之分佈

為進一步理解整體投資組合績效的來源，本報告由投資組合層級轉向個股層級，檢視 746 支股票在 2017–2025 年完整測試期內的最終累積淨回報分佈。圖一呈現各股票最終淨回報的直方圖分佈（以 $\pm 50\%$ 為顯示範圍，5% 為分組寬度），並標示其平均值、中位數與分位數位置，以說明策略在橫斷面上的表現結構。



圖一 淨報酬率分布圖

從分佈結果來看，在 746 支股票中，共有 268 支股票呈現正的最終淨回報，占比約 35.9%；298 支股票呈現負回報，占比約 39.9%；另有 183 支股票的最終淨回報接近 0%，占比約 24.5%。此一結果顯示，策略在個股層級並非普遍性地創造正報酬，而是僅在部分股票上成功累積顯著收益。

進一步觀察報酬分佈的集中趨勢，圖一顯示個股最終淨回報的中位數僅約為 0.09%，而第 75 百分位數約為 3.31%，顯示超過一半的股票，其最終回報非常接近零。相對地，平均值則為 16.86%，明顯高於中位數，反映整體分佈呈現高度右偏（right-skewed）的特性，即少數股票貢獻了相對較大的正回報，進而拉高整體平均。


此分佈結構與前文第 6 章所說明的交易執行與部位控制機制高度一致。在本報告中，做空交易的部位

比例受到嚴格限制，僅以 $SHORT_FACTOR = 0.01$ 進行資金配置；因此，即便某些股票在測試期內出現做空訊號，其實際投入資金規模極小，對最終累積淨回報的影響亦十分有限。對於同時缺乏高信心做多訊號、且僅零星觸發小額放空交易的股票而言，其最終淨回報自然集中於接近 0% 的區域。

換言之，圖一中大量集中於零回報附近的股票，並不代表策略在這些標的上判斷失敗，而是反映策略在兩階段篩選與保守放空部位控制下，選擇「不積極參與」這些股票的交易。策略的整體報酬，主要來自於少數在測試期內反覆通過一階技術指標篩選與二階 XGB 高信心判斷的股票，其累積正回報在橫斷面上形成右尾，最終推升等權重投資組合的整體績效。

綜合而言，個股層級最終淨回報的分佈顯示，本報告策略並非追求在多數股票上取得小幅正報酬，而是透過嚴格的訊號篩選與風險控制，將資金集中配置於少數高信心交易機會，並在其上累積不對稱的正向收益。此一「低勝率、右尾驅動」的橫斷面特性，與前節所呈現之高累積報酬與高 Sharpe ratio 結果相互呼應。

7.3 投資組合累積報酬曲線與市場階段分析



圖二 等權重投資組合累積報酬

圖二呈現本報告策略於 2017 年至 2025 年測試期內的等權重投資組合累積報酬曲線，其中同時顯示不計交易成本之毛報酬（Gross Return）、納入交易成本後之淨報酬（Net Return），以及兩者之間所反映的累積交易成本影響。由於該曲線係由第 6 章所述之逐年滾動測試結果依時間順序串接而成，其時間變化可視為策略在不同市場階段下實際運作行為的總體呈現。

在 2017–2020 年初期階段，策略的累積報酬曲線呈現明顯下行趨勢，且淨報酬曲線的回撤幅度顯著大於毛報酬。此一現象顯示，策略在逆風或盤整偏空的市場環境中，不僅因交易訊號判斷失準而承受虧損，同時亦因交易頻率提高，使得每筆平倉 0.4% 的交易成本，以及放空交易進場時額外 0.2% 的成本持續累積，進一步放大整體回撤幅度。此階段可視為策略在結構性不利市場條件下的壓力測試，反映其對錯誤訊號與成本侵蝕的敏感性。

進入 2021–2022 年，累積報酬曲線出現極為顯著的跳升，無論在毛報酬或淨報酬層級，均呈現爆發式成長。此一跳升對應於前文所述之兩階段篩選機制在特定市場環境下的高度有效性：在該期間，市場趨勢與波動結構使技術指標的一階篩選能頻繁產生方向明確的訊號，而 XGB 模型的二階篩選則成功集中資金於高信心交易機會，透過非線性機率加權配置，快速累積正向報酬。即使在扣除顯著增加的交易成本後，淨報酬曲線仍保有大幅上升，顯示該階段的獲利能力足以完全吸收成本侵蝕。

在 2022–2024 年階段，策略的累積報酬成長明顯趨緩，甚至在 2022 年經歷第 7.1 章說提及的最大回撤-387.64%，淨報酬曲線呈現長時間的橫向盤整，而毛報酬與淨報酬之間的差距則持續擴大。此一現象顯示策略效率相較前一階段有所下降，交易所產生的邊際報酬不足以完全抵銷高頻交易下持續發生的交易成本。然而，值得注意的是，策略在此期間並未完全失效，其累積淨報酬並未出現結構性崩落，而是維持於相對穩定的水準，顯示兩階段篩選與保守放空部位控制仍具備一定程度的防禦效果。

進入 2025 年以後，累積報酬曲線再次出現明顯上行，最終使策略的淨報酬達到 926.02%，毛報酬達到 1475.77%。此結果顯示，儘管交易成本在整體測試期中累積高達 549.75%，策略仍能在長期、多市場階段的循環下，透過少數高效率時期的獲利，彌補先前的不利階段並創造顯著正的長期報酬。

整體而言，圖二所呈現的累積報酬動態顯示，本報告策略的獲利並非均勻分佈於整個測試期，而是高度依賴特定市場環境下的報酬集中現象。此特性與前節所觀察到的「個股報酬右尾驅動」橫斷面結果相互呼應，共同說明策略的長期正報酬來源，主要來自於在少數有利市場階段中，成功放大高信心交易機會所累積的不對稱收益。


7.4 XGB 進場信心分級下之做多與做空策略報酬貢獻分析

為進一步釐清 XGB 模型在不同交易方向上的實際篩選效果，本報告在延續前節分析邏輯的基礎上，將所有已完成結算之交易，依其進場方向拆分為做多（Long）與做空（Short）兩個子策略，並分別檢視各自於不同進場信心區間（1% bucket）下，對整體加權淨報酬的貢獻情形。圖三上半部呈現做多策略的結果，下半部則呈現做空策略的對應分析。

在做多策略部分，圖三顯示 XGB 預測信心與累積報酬之間存在明顯且穩定的正向關係。當進場信心落於較低區間（接近做多門檻 60%）時，其對總報酬的貢獻有限，且個別區間偶有小幅負值；然而，隨著信心值上升至中高區間（約 0.70–0.80），對應的累積加權淨報酬顯著放大，成為整體策略最主要的獲利來源。此結果顯示，XGB 模型對做多交易所提供的預測機率，在實際交易中具備良好的排序能力，高信心做多交易不僅勝率較高，且在非線性資金配置下，能有效累積不對稱的正向收益。

相較之下，做空策略呈現出截然不同的特性。圖三下半部顯示，即使在較高的進場信心區間，做空交易對整體報酬的貢獻仍然普遍偏低，且多數信心區間的累積加權淨報酬為負。此結果並不代表 XGB 模型在做空方向上完全失效，而是反映本報告在策略設計上，對做空交易施加了多層次且高度保守的風險控制。首先，做空交易需通過較高的進場機率門檻（70%），使得樣本數本身即相對有限；其次，即便允許進場，其資金配置仍受到 $SHORT_FACTOR = 0.01$ 的嚴格限制，使得單筆做空交易對整體報酬的影響幅度顯著低於做多交易；最後，做空交易尚需額外承擔進場時 0.2% 的放空成本，使其在邊際報酬不足時更容易被交易成本侵蝕。這個結果顯示將做多和做空的策略一起放入 XGB 模型考慮可能無法釐清進出場的正確時機，反而被混淆，分析結果支持應該要將做多和做空的策略分開兩個模型

訓練的必要性。



圖三 XGB 進場信心分級下之做多與做空策略報酬貢獻

從整體角度來看，圖三清楚顯示本報告策略的長期正報酬，幾乎完全由高信心做多交易所驅動，而做空策略在本架構下主要扮演的是輔助性角色，其功能更偏向於在特定市場環境中提供有限的對沖或方向性修正，而非主要獲利來源。此一結果與前文第 6 章所述之方向性門檻設定、非線性資金配置以及放空部位控制邏輯完全一致，顯示策略在設計層面即已預期做多與做空在報酬結構上的非對稱性。

綜合而言，將交易樣本依方向拆分後的分析進一步驗證了 XGB 模型在做多方向上的實際辨識能力，並同時說明做空策略在嚴格風險約束下，其對整體績效的影響被刻意限制。此結果不僅補充了前節混合樣本分析的解釋，也使投資策略在「模型判斷—資金配置—最終報酬」三者之間的因果關係更加清晰。

7.5 投資績效實證結果之整體評析

本章實證結果顯示，本報告所建構之投資策略在 2017–2025 年測試期內，能於扣除實際交易成本後，仍累積顯著正的長期報酬，且在風險調整後績效上明顯優於同期台灣股市大盤。策略的超額報酬並非均勻分佈於所有交易或市場階段，而是高度集中於特定有利環境下的高信心交易機會，呈現明顯的不對稱報酬結構。

進一步的個股層級與信心分級分析顯示，整體績效主要由高信心的做多交易所驅動，而做空交易在較高門檻、嚴格部位限制與額外成本約束下，僅扮演輔助性角色。此結果與第 6 章所述之兩階段篩選、方向性機率門檻與非線性資金配置設計高度一致，顯示策略在模型判斷、資金配置與最終報酬之間具備清楚且一致的因果關係，為後續策略限制與改進方向的討論提供實證基礎。

第八章 總結

本報告建構了一個結合多樣化技術指標與 XGBoost 二階篩選的量化交易系統，並透過嚴謹的滾動視窗架構實證其效能。研究結果總結如下：

- **優異的風險調整表現：**策略在 2017–2025 年測試期內，扣除交易成本後的累積淨報酬達 **926.02%**，年化淨報酬為 **29.91%**。Sharpe ratio 達 **3.27**，遠高於大盤同期的 0.74，顯示兩階段篩選機制能顯著提升單位風險的獲利潛力。
- **二階篩選之有效性：**實證顯示，XGB 模型對做多交易具備良好的排序能力。隨著預測機率（進場信心）上升，累積加權淨報酬顯著增加，證實了機器學習能有效從市場特徵中識別高成功率的交易時點。
- **非對稱報酬驅動：**本策略呈現典型的「低勝率、右尾驅動」特性。整體收益並非來自普遍性的獲利，而是高度依賴少數高信心做多交易在特定市場環境（如 2021–2022 年）下的爆發式成長。
- **策略限制與未來方向：**做空策略在嚴格的門檻（70%）、資金限制（SHORT_FACTOR=0.01）及額外成本下，對整體績效貢獻有限，且易受混淆。分析結果支持未來應將做多與做空策略拆分為獨立模型進行訓練，以優化不同方向的決策品質。

綜上所述，本研究所採用的巢狀滾動視窗設計，確保了策略參數具備時間穩定性，並證實了「指標提議、模型定決策」的雙階段架構具備高度的實務應用價值。

致謝（Acknowledgement）

謹此誠摯感謝李冠緯^{*}、林雨萱[†]與張力仁[‡]於本研究過程中提供之寶貴的貢獻，特別是在模型架構中所採用的技術指標給予必要的建議。其在方法論層面的洞見與技術上的支援，對本研究之順利完成與成果品質的提升具有關鍵性的貢獻，特此致以最深的謝意。

^{*} Department of Applied Mathematics, National Sun Yat-sen University.

[†] Department of Applied Mathematics, National Sun Yat-sen University.

[‡] Department of Business Management, National Sun Yat-sen University.